

**PROYEK UJIAN AKHIR SEMESTER
MATA KULIAH DATA MINING I
KELAS SD - A1**

**ANALISIS POLA HIDUP MAHASISWA TSD 22 BERDASARKAN PENDAPATAN
PERBULAN**



Kelompok C SD - A1:

- | | |
|------------------------------------|--------------------|
| 1. Dara Devinta Faradhilla | (164221002) |
| 2. Brilliant Prigar Ednesto | (164221024) |
| 3. Reinhart Ananda Siswadi | (164221046) |
| 4. Romero Rachmat Musadat | (164221070) |
| 5. Muhammad Firdaus Mu'afi | (164221092) |

**TEAM-BASED PROJECT
MATA KULIAH DATA MINING I
PROGRAM STUDI S1 - TEKNOLOGI SAINS DATA
FAKULTAS TEKNOLOGI MAJU DAN MULTIDISIPLIN
UNIVERSITAS AIRLANGGA
2024**

DAFTAR ISI

DAFTAR ISI.....	1
DAFTAR TABEL.....	3
DAFTAR GAMBAR.....	4
BAB I.....	5
1.1 LATAR BELAKANG.....	5
1.2 RUMUSAN MASALAH.....	5
1.3. TUJUAN PENELITIAN.....	5
1.4 MANFAAT PENELITIAN.....	6
BAB II.....	7
2.1 TINJAUAN STATISTIKA.....	7
2.1.1 Ukuran Sampel.....	7
2.1.2 Teknik Sampling.....	7
2.1.3 Label encoding.....	7
2.1.4 Decision Tree Classifier.....	7
2.1.5 Random Forest Classifier.....	8
2.1.6 KNN Classifier.....	8
2.1.7 Naive Bayes.....	9
2.1.8 Metode Ensemble: Bagging.....	9
2.1.9 ANN: BackPropagation.....	9
2.1.10 Confusion Matrix.....	10
2.1.10 Classification.....	10
2.2 TINJAUAN NON-STATISTIKA.....	10
2.2.1. Pendapatan Mahasiswa.....	10
2.2.2. Pola Hidup Mahasiswa.....	11
BAB III.....	12
3.1 METODE PENGAMBILAN SAMPEL.....	12
3.2 VARIABEL PENELITIAN.....	12
3.3 METODE ANALISIS.....	13
3.3.1. Decision Tree.....	13
3.3.2. Random Forest.....	13
3.3.3. Bagging.....	13
3.3.4. KNN Classification.....	13
3.3.5. Artificial Neural Network.....	14
BAB IV.....	15
4.1 Deskripsi Data.....	15

4.2 Data Pre-Processing.....	16
4.2.1 Missing Value.....	16
4.2.2 Visualisasi Data.....	16
4.2.3 Transformasi Variabel.....	18
4.2.4 Label Encoding.....	18
4.2.5 Feature Encoding.....	18
4.2.7 Drop Column.....	20
4.2.8 Imbalance Data.....	20
4.3 Pemodelan Machine Learning.....	21
4.3.1 Decision Tree.....	21
4.3.2 Random Forest.....	22
4.3.3 K-Nearest Neighbor (KNN).....	23
4.3.4 Bagging: Decision Tree.....	23
4.3.5 Bagging: Random forest.....	24
4.3.6 Naive-Bayes.....	24
4.3.7 Artificial Neural Network: Backwards-Propagation.....	25
4.3.8 Perbandingan Evaluasi Model.....	25
BAB V.....	27
5.1 KESIMPULAN.....	27
5.2 SARAN.....	27
DAFTAR PUSTAKA.....	28
LAMPIRAN.....	29

DAFTAR TABEL

Tabel 4.1 Tabel label.....	20
----------------------------	----

DAFTAR GAMBAR

Gambar 4.1 Data Understanding.....	15
Gambar 4.2 Hasil pencarian Missing value.....	16
Gambar 4.3 Histogram setiap variabel kategorik.....	16
Gambar 4.4 Bar Chart Distribusi Usia.....	17
Gambar 4.5 Boxplot usia.....	17
Gambar 4.6 Boxplot distribusi pendapatan.....	18
Gambar 4.7 Hasil Label Encoding.....	18
Gambar 4.8 Grafik Features Importance.....	19
Gambar 4.9 Heatmap korelasi antar variabel.....	20
Gambar 4.10 Histogram variabel pendapatan.....	21
Gambar 4.11 Balancing data.....	21
Gambar 4.12 Akurasi Decision Tree.....	21
Gambar 4.13 Akurasi Random Forest.....	22
Gambar 4.14 Akurasi KNN.....	23
Gambar 4.15 Akurasi Bagging: Decision Tree.....	23
Gambar 4.16 Akurasi Bagging: Random Forest.....	24
Gambar 4.17 Naive Bayes.....	24
Gambar 4.18 Akurasi ANN.....	25
Gambar 4.19 Perbandingan evaluasi model.....	25

BAB I

PENDAHULUAN

1.1 LATAR BELAKANG

Kehidupan mahasiswa pada era digital ini tidak hanya dipengaruhi oleh faktor internal seperti minat dan bakat pribadi, tetapi juga oleh lingkungan eksternal yang semakin dinamis. Perkembangan teknologi informasi dan komunikasi telah merubah paradigma dalam berbagai aspek kehidupan, termasuk cara mahasiswa mengelola keuangan dan mengatur pola hidup mereka. Di tengah arus informasi dan transformasi digital yang terus berkembang, mahasiswa Teknologi Sains Data angkatan 2022 menjadi representasi dari generasi yang tidak hanya terkoneksi dengan teknologi, namun juga dihadapkan pada tantangan finansial dan keputusan pola hidup yang kompleks.

Pola hidup mahasiswa mencakup beberapa aspek, seperti frekuensi penggunaan transportasi, jumlah makan per hari, seringnya berbelanja online,, dan frekuensi memesan ojek online. Semua ini adalah variabel penting yang mempengaruhi pengeluaran bulanan mereka, yang pada akhirnya berkaitan langsung dengan pendapatan bulanan yang mereka terima dari orang tua.

Penggunaan transportasi, baik itu kendaraan pribadi, transportasi umum, atau ojek online, membutuhkan alokasi dana tertentu yang mempengaruhi pengeluaran bulanan. Begitu juga dengan kebiasaan makan; apakah mereka lebih sering memasak sendiri yang mungkin lebih ekonomis, atau lebih sering makan di luar yang cenderung lebih mahal. Kebiasaan berbelanja online juga dapat meningkatkan pengeluaran jika tidak dikendalikan dengan baik.

Dengan demikian, dalam penelitian ini, kami ingin mengklasifikasikan mahasiswa Teknologi Sains Data angkatan 2022 berdasarkan pendapatan per bulan, serta menganalisis lebih dalam hubungan antara pola hidup mereka dan pendapatan bulanan yang diperoleh dari orang tua. Pemahaman yang mendalam mengenai bagaimana pola hidup mempengaruhi pengeluaran dan pendapatan akan memberikan wawasan yang berguna dalam membantu mahasiswa mengelola keuangan mereka dengan lebih efektif.

1.2 RUMUSAN MASALAH

Berdasarkan latar belakang masalah yang telah diuraikan diatas, maka permasalahan yang akan dibahas dalam penelitian ini dapat dirumuskan sebagai berikut:

- 1.2.1 Apakah terdapat hubungan yang signifikan antara pola hidup mahasiswa Teknologi Sains Data angkatan 2022 dengan pendapatan per bulan yang diterima dari orang tua?
- 1.2.2 Apa faktor-faktor penentu utama yang mempengaruhi pendapatan per bulan Program Studi Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mahasiswa?
- 1.2.3 Bagaimana performa dan akurasi model klasifikasi dalam memprediksi pendapatan per bulan Program Studi Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mereka?

1.3. TUJUAN PENELITIAN

Tujuan dari penelitian ini sesuai dengan perumusan masalah di atas adalah sebagai berikut:

- 1.3.1 Menganalisis hubungan antara pola hidup mahasiswa Teknologi Sains Data angkatan 2022 dengan pendapatan per bulan yang diterima dari orang tua.
- 1.3.2 Mengidentifikasi faktor-faktor penentu utama yang mempengaruhi pendapatan per bulan mahasiswa Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mereka.
- 1.3.3 Mengevaluasi performa dan akurasi model klasifikasi dalam memprediksi pendapatan per bulan mahasiswa Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mereka.

1.4 MANFAAT PENELITIAN

Manfaat penelitian yang diharapkan dapat dicapai dalam penelitian ini meliputi:

- 1.4.1 Memberikan pemahaman yang lebih mendalam tentang bagaimana pendapatan setiap mahasiswa Program Studi Teknologi Sains Data angkatan 2022 pola hidup mereka.
- 1.4.2 Menyediakan informasi tentang faktor-faktor yang mempengaruhi pendapatan per bulan dari orang tua mahasiswa Program Studi Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mereka, sehingga dapat membantu pihak perguruan tinggi atau lembaga pendidikan dalam merancang program bantuan atau dukungan yang lebih tepat dan efektif bagi mahasiswa dengan berbagai tingkat pendapatan.
- 1.4.3 Membangun model klasifikasi yang dapat membantu pihak perguruan tinggi atau lembaga pendidikan dalam memprediksi pendapatan per bulan mahasiswa Program Studi Teknologi Sains Data angkatan 2022 berdasarkan pola hidup mereka secara akurat, sehingga mereka dapat mengidentifikasi dan memberikan solusi yang sesuai untuk memenuhi kebutuhan dan aspirasi mahasiswa.

BAB II

TINJAUAN PUSTAKA

2.1 TINJAUAN STATISTIKA

2.1.1 Ukuran Sampel

Sampel adalah bagian dari jumlah dan karakteristik yang dimiliki oleh populasi tersebut (Sugiyono, 2010). Populasi merujuk pada keseluruhan individu atau objek yang ingin digeneralisasi atau ditarik kesimpulannya, sementara ukuran sampel adalah jumlah individu yang dipilih dari populasi (Creswell, 2014). Ukuran sampel yang tepat penting untuk menggeneralisasi temuan ke seluruh populasi, dan berbagai teknik sampling seperti random sampling, stratified sampling, sering digunakan untuk pemilihan sampel yang tepat. Pertimbangan dalam menentukan ukuran sampel meliputi tujuan penelitian, karakteristik populasi, metode analisis, dan sumber daya yang tersedia. Ukuran sampel yang tidak memadai akan menghasilkan kesimpulan yang bias, sementara ukuran sampel yang terlalu besar dapat menghabiskan sumber daya yang tidak perlu, sehingga penting untuk mencapai keseimbangan yang tepat.

2.1.2 Teknik Sampling

Dalam pemilihan sampel yang mewakili populasi mahasiswa program studi Teknologi Sains Data Universitas Airlangga angkatan 2022, peneliti dapat menggunakan metode non-probability sampling, khususnya convenience atau accidental sampling. Metode ini dipilih karena praktis dan mudah diterapkan, terutama dalam situasi di mana peneliti membutuhkan responden yang mudah diakses dalam waktu yang singkat dan dengan sumber daya yang terbatas.

2.1.3 Label encoding

Label Encoder adalah cara cepat dan mudah untuk mengubah label kategorik menjadi angka dalam machine learning, dengan memberikan angka unik pada setiap kategori (Mafa'atih, 2020).. Namun, perlu diingat bahwa urutan angka ini mungkin tidak relevan dan bisa menyebabkan kesalahan interpretasi oleh algoritma. Alternatif seperti One-Hot Encoding atau Target Encoding bisa menjadi pilihan yang lebih baik tergantung pada data dan tujuan analisis.

2.1.4 Decision Tree Classifier

Decision tree merupakan metode dalam machine learning yang digunakan untuk pengambilan keputusan berbasis pemodelan pohon, di mana setiap cabang merepresentasikan keputusan dan hasil yang mungkin. Metode ini populer karena kesederhanaannya dalam interpretasi dan kemampuannya menangani data dengan atribut yang heterogen. Decision tree menggunakan teknik “membagi dan menaklukkan” untuk membagi ruang pencarian masalah menjadi himpunan masalah (dunham,

2003).Kelebihan utama dari decision tree adalah kemampuannya menangani data yang missing dan mengkombinasikan variabel input yang berbeda jenis. Decision tree juga menjadi dasar metode ensemble seperti Random Forests yang menggabungkan multiple decision trees untuk meningkatkan performa prediktif (Breiman, 2001).

2.1.5 Random Forest Classifier

Random Forest adalah metode ensemble dalam machine learning yang menggabungkan banyak decision tree untuk meningkatkan akurasi dan kestabilan prediksi. Salah satu keunggulan utamanya adalah mengurangi overfitting yang umum pada decision tree individual, menghasilkan model yang lebih generalis dan robust. Random Forest juga efektif menangani data dengan missing values dan variabel input yang berbeda jenis serta memberikan estimasi pentingnya variabel untuk seleksi fitur dan interpretasi model (Breiman, 2001).

- a. Dilakukan resampling dengan metode bootstrap, yaitu pengambilan sampel secara acak dengan pengembalian, dari training data sebanyak n jumlah observasi.
- b. Dibuatkan decision tree untuk setiap data hasil resampling.
- c. Diadakan voting di setiap sampel untuk mencari kelas dengan suara terbanyak. Kelas yang menang dijadikan hasil prediksi model.

2.1.6 KNN Classifier

Algoritma k-Nearest Neighbor (k-NN) adalah metode klasifikasi yang mengandalkan konsep "tetangga terdekat". Dalam konteks ini, "k" mengacu pada jumlah tetangga terdekat yang akan dipertimbangkan dalam menentukan kelas suatu data baru (data uji). Kedekatan antar data diukur menggunakan konsep jarak, yang telah dibahas dalam konsep similarity dan dissimilarity (Witten et al., 2011).

Salah satu metode yang paling umum digunakan untuk menghitung jarak dalam k-NN adalah Euclidean distance. Metode ini memungkinkan kita untuk menentukan secara kuantitatif seberapa dekat atau jauh suatu data uji dengan tetangga-tetangganya, sehingga dapat dilakukan klasifikasi berdasarkan mayoritas kelas dari tetangga terdekat tersebut.

- a. Menghitung Jarak: KNN menghitung jarak antara data baru dan semua titik dalam dataset pelatihan, biasanya menggunakan jarak Euclidean atau Manhattan.
- b. Menentukan K Tetangga Terdekat: Memilih K titik data terdekat berdasarkan jarak yang dihitung. Nilai K ditentukan pengguna dan mempengaruhi kinerja algoritma.
- c. Voting Kelas Mayoritas: Dari K tetangga terdekat, KNN melakukan voting untuk menentukan kelas mayoritas yang menjadi prediksi untuk data baru.

2.1.7 *Naive Bayes*

Naive Bayes Classifier merupakan sebuah metode klasifikasi yang berakar pada teorema Bayes (Suntoro, 2019). Pengklasifikasi Bayesian naif (*naïve Bayesian classifier*) terkenal karena akurasi dan kecepatannya, terutama pada database besar. Metode ini mengasumsikan bahwa nilai atribut satu sama lain independen dalam konteks kelas tertentu, yang menyederhanakan perhitungan sehingga dianggap "naif". Kelebihan utamanya adalah kesederhanaan, efisiensi, dan kemampuannya menangani dataset besar.

2.1.8 Metode Ensemble: Bagging

Bagging adalah metode ensemble yang populer untuk meningkatkan performa model klasifikasi dengan melatih beberapa model secara paralel pada subset data berbeda. Metode ensemble adalah metode gabungan dari beberapa model untuk menghasilkan model dengan performa yang lebih baik. Meskipun efektif mengatasi overfitting, bagging memiliki kekurangan seperti biaya komputasi tinggi, potensi underfitting, kompleksitas interpretasi, dan sensitivitas terhadap data berkualitas rendah. Alternatif seperti boosting dan stacking juga perlu dipertimbangkan, tergantung pada kebutuhan dan karakteristik data.

1. Bagging pada Decision Tree:

Decision tree mempelajari gangguan dalam data pelatihan, bukan pola yang mendasarinya. Hal tersebut membuat Decision tree sangat rentan terhadap overfitting. Oleh sebab itu, bagging dilakukan pada Decision Tree karena dapat mengurangi overfitting dengan membuat rata-rata prediksi beberapa Trees, masing-masing dilatih pada data yang sedikit berbeda. Proses rata-rata ini memperlancar prediksi dan membuat model lebih dapat digeneralisasikan ke data baru.

2.1.9 ANN: *BackPropagation*

Backpropagation adalah metode Jaringan Syaraf Tiruan (JST) yang menggunakan pembelajaran terawasi (Setiawan, 2011). Proses ini melibatkan dua langkah utama: propagasi maju, di mana input diproses melalui jaringan untuk menghasilkan output, dan propagasi mundur, di mana kesalahan dihitung dan disebarkan kembali melalui jaringan untuk menyesuaikan bobot. Tujuannya adalah untuk meminimalkan kesalahan prediksi dan meningkatkan akurasi model. Metode ini populer dalam berbagai aplikasi seperti pengenalan pola, peramalan, dan optimasi (Amri, 2015). Keunggulannya terletak pada penggunaan pembelajaran terawasi, di mana pola masukan dan target diberikan sebagai pasangan data. Proses pelatihan melibatkan tahap maju untuk menghitung error keluaran, diikuti tahap mundur untuk menyesuaikan bobot dan meminimalkan error tersebut (Amri, 2015). Tujuan utama *Backpropagation* adalah mencapai keseimbangan antara kemampuan jaringan mengenali pola pelatihan dan memberikan respon yang benar terhadap pola masukan baru.

2.1.10 Confusion Matrix

Evaluasi model klasifikasi melibatkan dua aspek utama: metrik dan partisi data (Han et al., 2012). Confusion matrix digunakan untuk memperoleh berbagai metrik seperti akurasi, sensitivitas, spesifisitas, presisi, dan F-measure, yang mengukur kemampuan prediksi model. Namun, akurasi dapat menyesatkan ketika kelas minoritas menjadi perhatian utama. Partisi data menjadi himpunan pelatihan dan uji dilakukan menggunakan metode seperti holdout, random sampling, cross-validation, atau bootstrapping.

a. Precision :

$$Precision = \frac{\text{jumlah prediksi benar (positif)}}{\text{prediksi benar (positif)} + \text{prediksi salah (positif)}}$$

b. Recall :

$$Recall = \frac{TP}{TP + FN}$$
$$Recall = \frac{\text{jumlah prediksi benar (positif)}}{\text{prediksi benar (positif)} + \text{prediksi salah (negatif)}}$$

c. F1-score :

$$F1\ Score = 2 \times \frac{Recall \times Precision}{Recall + Precision}$$

d. Accuracy :

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2.1.10 Classification

Kinerja pengklasifikasi diukur berdasarkan tingkat kesalahan. Namun, tingkat kesalahan pada data pelatihan (data yang digunakan untuk melatih pengklasifikasi) cenderung optimis dan tidak mencerminkan kinerja pada data baru. Untuk estimasi kinerja yang realistis, diperlukan data uji independen (Witten et al., 2011). Dalam praktiknya, digunakan tiga dataset: data pelatihan untuk membangun pengklasifikasi, data validasi untuk optimasi, dan data uji untuk menghitung tingkat kesalahan akhir. Ketiga dataset ini harus dipilih secara independen (Witten et al., 2011).

2.2 TINJAUAN NON-STATISTIKA

2.2.1. Pendapatan Mahasiswa

Pendapatan mahasiswa merupakan topik penting dalam studi ekonomi dan sosial. Penelitian terkait sering kali mencakup faktor-faktor yang mempengaruhi pendapatan mahasiswa, termasuk pekerjaan paruh waktu, dukungan keuangan dari keluarga, tingkat pendidikan, dan aspek demografis lainnya. Faktor-faktor ini memainkan peran penting dalam pemahaman tentang kondisi keuangan mahasiswa dan dapat membantu dalam

merancang kebijakan yang lebih efektif untuk mendukung kesejahteraan finansial mereka.

2.2.2. Pola Hidup Mahasiswa

Pola hidup mahasiswa dan pendapatan mereka telah menjadi fokus penelitian di bidang psikologi, sosiologi, dan ekonomi. Smith dan Brown (2018) menemukan bahwa mahasiswa dengan pendapatan lebih tinggi cenderung memiliki pola konsumsi yang lebih bervariasi dan gaya hidup yang lebih mahal. Penelitian oleh Johnson et al. (2015) menunjukkan bahwa pekerjaan paruh waktu, dukungan keuangan keluarga, dan manajemen keuangan pribadi juga mempengaruhi pola hidup mahasiswa. Memahami hubungan ini penting untuk merancang program pendidikan dan dukungan finansial yang sesuai dengan kebutuhan mahasiswa.

BAB III

METODOLOGI PENELITIAN

3.1 METODE PENGAMBILAN SAMPEL

Data yang digunakan pada proyek ini adalah Data Primer yang dikumpulkan dari Mahasiswa Teknologi Sains Data angkatan 2022 melalui Google form. Pengumpulan data dilakukan dengan metode convenience sampling dengan mengirim form di grup angkatan 2022 dan menghubungi setiap mahasiswa untuk mendapatkan datanya.

Metode yang digunakan untuk menentukan jumlah sampel mahasiswa adalah metode slovin dengan alpha 0.05. Rumus yang kami gunakan yaitu :

$$n = \frac{N}{1+Ne^2}$$
$$n = \frac{113}{1+113(0,05)^2} = 88$$

Dari perhitungan, minimal sampel yang diambil yaitu sebanyak 88. Kami mengambil sebanyak 94 sampel dari populasi mahasiswa yang berjumlah 113 mahasiswa.

3.2 VARIABEL PENELITIAN

Dalam proyek ini, kami menggunakan 15 variabel untuk mendapatkan analisis pola hidup mahasiswa Teknologi Sains Data angkatan 2022 berdasarkan pendapatan per bulan. Variabel-variabel nya yaitu:

- | | |
|---------------------|---|
| a. Jenis Kelamin | : Jenis kelamin responden |
| b. Usia | : Usia responden |
| c. Pendapatan | : Pendapatan per bulan |
| d. Transportasi | : Jenis transportasi yang digunakan sehari-hari |
| e. Makan | : Jumlah makan dalam sehari |
| f. Masak Sendiri | : Frekuensi memasak dengan membeli makanan |
| g. Belanja Online | : Berbelanja online dalam sebulan |
| h. Nongkrong | : Jumlah nongkrong dalam sebulan |
| i. Tabung | : Menabung atau tidak |
| j. Merasa Cukup | : Kecukupan dalam memenuhi kebutuhan bulanan |
| k. Merokok | : Merokok atau tidak |
| l. Aktif Organisasi | : Mengikuti organisasi atau tidak |
| m. Jajan Mall | : Frekuensi pergi ke pusat perbelanjaan |
| n. Ojol | : Frekuensi menggunakan transportasi umum |
| o. Pengeluaran | : Pengeluaran per bulan |

3.3 METODE ANALISIS

3.3.1. Decision Tree

Decision Tree adalah metode pemodelan prediktif dalam analisis data yang menggunakan struktur pohon. Decision Tree digunakan untuk mempelajari klasifikasi dan prediksi pola dari data dan menggambarkan relasi dari variabel atribut x dan variabel target y dalam bentuk pohon. Algoritma ini bekerja dengan membagi dataset menjadi subset yang lebih kecil dan lebih kecil lagi.

Prinsip dasar decision tree yaitu node root (akar) yang merupakan node teratas dari pohon, splitting yang merupakan pemisahan dataset, node leaf yang memberikan prediksi dan pruning yang mengurangi ukuran dan menghilangkan node yang tidak signifikan. Proses pembuatan pohon melibatkan pemilihan fitur terbaik untuk membagi dataset biasanya menggunakan metrik seperti Entropy yang mengukur ketidakpastian dalam dataset

$$Entropy(S) = - \sum_{i=1}^c p_i \log_2 p_i$$

3.3.2. Random Forest

Random Forest adalah metode yang dapat meningkatkan hasil akurasi dalam membangkitkan atribut untuk setiap node yang dilakukan secara acak. Random Forest terdiri dari sekumpulan decision tree, dimana kumpulan pohon keputusan ini digunakan untuk mengklasifikasi data ke suatu kelas. Random Forest dirancang untuk meningkatkan akurasi dan mengurangi overfitting. Penggunaan Algoritma Random Forest untuk klasifikasi dapat diterapkan pada data imbalance dalam jumlah besar dengan memberikan hasil performa yang baik dan waktu eksekusi yang cepat.

3.3.3. Bagging

Bagging atau Bootstrap Aggregating adalah metode ensemble learning yang efektif dalam mengoptimalkan proses klasifikasi. Bagging juga berguna untuk memperbaiki kinerja algoritma klasifikasi pada machine learning dan untuk meningkatkan akurasi klasifikasi dengan menggabungkan klasifikasi tunggal. Bagging melakukan Bootstrap atau teknik sampling pada data asli sebanyak n kali dengan penggantian untuk membuat set pelatihan. Metode Bagging memiliki beberapa tahap yaitu Bootstrap Sampling, Model Training, dan Aggregating.

3.3.4. KNN Classification

K-Nearest Neighbor adalah sebuah metode untuk melakukan klasifikasi terhadap objek berdasarkan data pembelajaran yang jaraknya paling dekat dengan objek tersebut. Algoritma ini bersifat non-parametrik dan lazy learning, yang berarti bahwa KNN tidak membuat asumsi apapun tentang distribusi data dan tidak melakukan pembelajaran

eksplisit dari model. Prinsip dasar KNN yaitu training set dimana KNN bekerja dengan mengacu pada data latih yang sudah ada dan mengklasifikasikan jarak data. Metode yang paling sering digunakan adalah jarak Euclidean dengan rumus :

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

3.3.5. Artificial Neural Network

Artificial Neural Network adalah metode komputasi yang meniru sistem jaringan biologis yang menggunakan perhitungan non-linier dasar. ANN terdiri dari lapisan-lapisan neuron yang saling terhubung dan mampu mempelajari hubungan non-linear dalam data.

Struktur dasar ANN terdiri dari:

- Input Layer: Lapisan yang menerima data input.
- Hidden Layer(s): Lapisan yang menyembunyikan proses komputasi di dalamnya.
- Output Layer: Lapisan yang menghasilkan output atau prediksi.

Proses ANN dibagi menjadi Forward Propagation, Loss Calculation, Backpropagation dan Gradient Descent.

- Forward Propagation : proses input data melewati jaringan lapisan input
- Loss Calculation : fungsi untuk mengukur seberapa baik model memprediksi target output
 - Cross-Entropy Loss

$$L(x, y) = - \sum_{i=1}^c x_i \log_2 y_i$$

- Backpropagation : untuk menghitung gradien fungsi loss
- Gradient Descent : algoritma optimisasi untuk memperbarui bobot dan bias

BAB IV HASIL DAN ANALISIS

4.1 Deskripsi Data

	Jenis_Kelamin	pendapatan	transportasi	makan	masak_sendiri	belanja_online	nongkrong	tabung	merasa_cukup	merokok	aktif_org	jajan_mall	ojol	pengeluaran
count	94	94	94	94	94	94	94	94	94	94	94	94	94	94
unique	2	5	6	3	4	4	4	3	3	2	2	3	3	5
top	Perempuan	1.000.000 - 1.500.000 IDR	Motor	Dua kali	Lebih sering membeli makanan di luar	1-2 kali	1-2 kali	Ya, kadang-kadang	Cukup, tetapi tidak selalu bisa menabung	Tidak	Ya	Jarang	Jarang	1.000.001 - 1.500.000 IDR
freq	49	25	55	51	46	55	41	50	51	85	53	58	53	27

Gambar 4.1 Data Understanding

Berdasarkan analisis, total data yang diperoleh berjumlah 94 entri. Rincian untuk masing-masing variabel adalah sebagai berikut:

- Variabel 'Jenis_Kelamin' memiliki 2 kategori, dengan kategori 'perempuan' sebagai yang terbanyak, yaitu sebanyak 49.
- Variabel 'pendapatan' memiliki 5 kategori, dengan kategori '1.000.000 - 1.500.000 IDR' sebagai yang terbanyak, yaitu sebanyak 25.
- Variabel 'transportasi' memiliki 6 kategori, dengan kategori 'Motor' sebagai yang terbanyak, yaitu sebanyak 55.
- Variabel 'makan' memiliki 3 kategori, dengan kategori 'Dua kali' sebagai yang terbanyak, yaitu sebanyak 51.
- Variabel 'masak_sendiri' memiliki 4 kategori, dengan kategori 'Lebih sering membeli makanan di luar' sebagai yang terbanyak, yaitu sebanyak 46.
- Variabel 'belanja_online' memiliki 4 kategori, dengan kategori '1-2 kali' sebagai yang terbanyak, yaitu sebanyak 55.
- Variabel 'nongkrong' memiliki 4 kategori, dengan kategori '1-2 kali' sebagai yang terbanyak, yaitu sebanyak 41.
- Variabel 'tabung' memiliki 3 kategori, dengan kategori 'Ya, kadang-kadang' sebagai yang terbanyak, yaitu sebanyak 50.
- Variabel 'merasa_cukup' memiliki 3 kategori, dengan kategori 'Cukup, tetapi tidak selalu bisa menabung' sebagai yang terbanyak, yaitu sebanyak 51.
- Variabel 'merokok' memiliki 2 kategori, dengan kategori 'tidak' sebagai yang terbanyak, yaitu sebanyak 85.
- Variabel 'aktif_org' (aktif dalam organisasi) memiliki 2 kategori, dengan kategori 'Ya' sebagai yang terbanyak, yaitu sebanyak 53.
- Variabel 'jajan_mall' memiliki 3 kategori, dengan kategori 'Jarang' sebagai yang terbanyak, yaitu sebanyak 58.
- Variabel 'ojol' memiliki 3 kategori, dengan kategori 'Jarang' sebagai yang terbanyak, yaitu sebanyak 53.
- Variabel 'pengeluaran' memiliki 5 kategori, dengan kategori '1.000.001 - 1.500.000 IDR' sebagai yang terbanyak, yaitu sebanyak 27.

Analisis ini memberikan gambaran yang jelas mengenai distribusi kategori dalam setiap variabel yang dianalisis.

4.2 Data Pre-Processing

4.2.1 Missing Value

Missing value adalah data yang hilang dalam dataset yang dapat mempengaruhi analisis dan performa model. Deteksi dan penanganan missing value penting dilakukan, misalnya dengan imputasi atau penghapusan data.


[illegible]

Gambar 4.2 Hasil pencarian Missing value

Seluruh atribut (Jenis_Kelamin, usia, pendapatan, transportasi, makan, masak_sendiri, belanja_online, nongkrong, tabung, merasa_cukup, merokok, aktif_org, jajan_mall, ojol, pengeluaran) tidak memiliki nilai yang hilang. Ini ditunjukkan dengan adanya nilai "False" di setiap baris dan kolom, yang berarti bahwa semua entri pada dataset ini terisi lengkap dan tidak ada data yang kosong.


4.2.2 Visualisasi Data

4.2.2.1 Visualisasi Data Kategorik




Gambar 4.3 Histogram setiap variabel kategorik

Interpretasi untuk visualisasi data kategorik ini sama dengan deskripsi data, perbedaannya adalah pada variabel pendapatan dan pengeluaran yang sebelumnya memiliki 5 kategori diperkecil menjadi 3 kategori. Untuk variabel pendapatan, kategori '< 2.000.000 IDR' menjadi yang tertinggi, yaitu sebanyak 39, sedangkan untuk variabel pengeluaran, kategori '1.000.000 - 2.000.000 IDR' menjadi yang tertinggi, yaitu sebanyak 29.



Gambar 4.4 Bar Chart Distribusi Usia


Grafik distribusi usia yang disajikan memperlihatkan bahwa sebagian besar dari responden berusia 20 tahun, lalu disusul dengan usia 19 tahun, 21 tahun, lalu 22 tahun.



Gambar 4.5 Boxplot usia

Setelah ditelusuri lebih lanjut menggunakan boxplot, kategori usia 22 tahun merupakan sebuah outlier. Dan dalam kasus ini, outlier dipertahankan untuk menjaga variasi data.

4.2.3 Transformasi Variabel



Gambar 4.6 Boxplot distribusi pendapatan

Variabel transformation (transformasi variabel) adalah proses mengubah skala atau distribusi dari sebuah variabel. Dalam kasus ini, variabel pendapatan dan pengeluaran yang sebelumnya terbagi menjadi 5 kategori telah disesuaikan menjadi hanya 3 kategori. Proses ini bertujuan untuk menyederhanakan data, meningkatkan keterkaitan antar variabel, dan meningkatkan akurasi model yang digunakan.

4.2.4 Label Encoding


	Jenis_Kelamin	usia	pendapatan	transportasi	makan	masak_sendiri	belanja_online	nongkrong	tabung	merasa_cukup	merokok	aktif_org	jajan_mall	ojol	pengeluaran
0	1	1	1	2	0	3	0	0	1	0	0	0	2	0	0
1	1	0	0	4	2	2	0	1	2	1	0	1	1	2	1
2	0	1	2	1	0	3	0	2	2	1	0	1	0	0	0
3	0	1	0	2	0	3	3	0	1	0	0	0	0	2	1
4	0	1	2	2	0	1	1	2	1	0	0	0	0	0	2

Gambar 4.7 Hasil Label Encoding

Label encoding yang telah kami lakukan mengubah nilai kategorikal menjadi nilai numerik agar bisa digunakan dalam analisis statistik atau model machine learning. Terdapat 14 kolom yang merepresentasikan berbagai karakteristik individu. Misalnya, kolom pendapatan dengan nilai 0, 1 dan 2 menunjukkan tingkat pendapatan yang berbeda. Setiap baris mewakili satu individu dengan karakteristik yang dijelaskan oleh nilai-nilai dalam kolom tersebut.

4.2.5 Feature Encoding

One-Hot Encoding adalah metode untuk mengubah data kategorik menjadi data biner agar bisa digunakan dalam analisis data atau model machine learning. Setiap kategori diubah menjadi kolom biner terpisah, dengan nilai 1 untuk kategori yang sesuai dan 0 untuk yang tidak sesuai.




Gambar 4.8 Grafik Features Importance

Histogram di atas menunjukkan kepentingan masing-masing variabel dalam model. Semakin tinggi nilainya, semakin penting variabel tersebut. Berikut adalah interpretasinya:

- a. Variabel 'pengeluaran' memiliki kepentingan sekitar 34.6%
- b. Variabel 'transportasi' memiliki kepentingan sekitar 11.7%
- c. Variabel 'belanja_online' memiliki kepentingan sekitar 7.9%
- d. Variabel 'nongkrong' memiliki kepentingan sekitar 7%
- e. Variabel 'ojol' memiliki kepentingan sekitar 5%
- f. Variabel 'makan' memiliki kepentingan sekitar 4.2%
- g. Variabel 'masak_sendiri' memiliki kepentingan sekitar 4%
- h. Variabel 'tabung' memiliki kepentingan sekitar 3.7%
- i. Variabel 'merasa_cukup' memiliki kepentingan sekitar 3.3%
- j. Variabel 'Jenis_Kelamin' memiliki kepentingan sekitar 2%
- k. Variabel 'usia' memiliki kepentingan sekitar 2%
- l. Variabel 'jajan_mall' memiliki kepentingan sekitar 1.6%
- m. Variabel 'merokok' memiliki kepentingan sekitar 0.6%
- n. Variabel 'aktif_org' memiliki kepentingan sekitar 0.5%

Kesimpulannya, variabel **pengeluaran** paling penting dalam model (34.6%). Variabel **transportasi** dan **belanja online** juga penting (11.7% dan 7.9%), sementara variabel **aktif organisasi** paling rendah (0.5%).



Gambar 4.9 Heatmap korelasi antar variabel

Nilai korelasi berada pada rentang -1 hingga 1 yang menunjukkan apakah hubungan kedua variabel tersebut berbanding lurus atau berlawanan. Jika nilai korelasi semakin mendekati angka 1 artinya semakin kuat hubungan antara kedua variabel tersebut, baik positif maupun negatif.

Dari visualisasi di atas, bisa dilihat bahwa variabel X dan Y yang memiliki korelasi positif tertinggi adalah variabel **pengeluaran** (X) dengan **pendapatan** (Y) yaitu sebesar 0,31, dan korelasi positif terendah adalah variabel **pendapatan** (X) dengan **usia** (Y) yaitu sebesar -0,0002. Sedangkan untuk korelasi negatif tertinggi terjadi antara variabel **pengeluaran** (X) dan **jenis kelamin** (Y) yaitu sebesar -0,38, serta korelasi negatif terendah terjadi antara variabel **transportasi** (X) dan **makan** (Y) yaitu sebesar -0,03.


4.2.6 Drop Column

Label	Keterangan
0	Pendapatan < 2.000.000 IDR
1	Pendapatan <= 2.000.000 IDR
2	Pendapatan > 2.000.000 IDR

Tabel 4.1 Tabel label

Dari 15 variabel yang tersedia, 4 variabel yaitu merokok, aktif_org, usia, dan jajan_mall telah dibuang. Keputusan ini didasarkan pada pertimbangan bahwa keempat variabel tersebut memiliki nilai yang relatif kecil pada grafik feature importance. Feature importance adalah metrik yang menunjukkan seberapa penting atau berpengaruh suatu variabel dalam memprediksi target dalam model machine learning. Oleh karena itu, jumlah variabel yang digunakan sekarang adalah 10, yang meliputi jenis_kelamin, pendapatan, transportasi, makan, masak_sendiri, belanja_online, nongkrong, tabung, merasa_cukup, dan qjol.

4.2.7 Imbalance Data



Gambar 4.10 Histogram variabel pendapatan

```
Counts before balancing:
pendapatan
0      39
2      32
1      23
Name: count, dtype: int64
Counts after balancing:
pendapatan
1      39
0      39
2      39
```

Gambar 4.11 Balancing data

Imbalance data atau ketidakseimbangan data adalah kondisi di mana jumlah sampel pada setiap kategori dalam dataset tidak proporsional atau menunjukkan perbedaan yang terlalu signifikan. Dalam kasus ini, variabel pendapatan merupakan variabel yang tidak seimbang dan memerlukan penanganan untuk meningkatkan kualitas model. Sebelum dilakukan proses penyeimbangan data, terlihat bahwa responden dengan pendapatan tipe (1) memiliki jumlah frekuensi 23, sedangkan pendapatan tipe (0) memiliki frekuensi 39, dan pendapatan tipe (2) memiliki frekuensi 3. Terdapat perbedaan yang cukup besar antara frekuensi pendapatan tipe (1) dengan tipe lainnya.

Dengan menggunakan metode ROS (Random Over Sampling), salinan pengamatan dari kategori yang kurang ditambahkan sehingga jumlah pengamatan menjadi seimbang. Hasilnya, ketiga tipe pendapatan memiliki jumlah frekuensi yang sama sebanyak 39.

4.3 Pemodelan Machine Learning

Hasil evaluasi beberapa model Machine Learning menunjukkan performa yang beragam dalam klasifikasi data. Berikut adalah rincian evaluasi beberapa model yang digunakan dalam analisis ini:

4.3.1 Decision Tree

```
Hasil Precision, Recall, F1-score dari Decision Tree (DT):
=====
- Precision : 0.7125
- Recall    : 0.7083333333333334
- F1-score  : 0.7050227732793523
=====

Classification Report:
=====
              precision    recall  f1-score   support

0             0.43         0.50         0.46         6
1             0.71         0.56         0.63         9
2             0.90         1.00         0.95         9

 accuracy          0.68
 macro avg         0.68
 weighted avg      0.71

Accuracy of Decision Tree is: 70.83333333333334
=====
```

Gambar 4.12 Akurasi Decision Tree

Hasil evaluasi model Decision Tree (DT) menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 71.25% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 70.83% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 70.50%.

Dengan akurasi keseluruhan sekitar 70.83%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.2 Random Forest

```

Hasil Precision, Recall, F1-score dari Random Forest (RF):
=====
- Precision : 0.8322916666666668
- Recall    : 0.8333333333333334
- F1-score  : 0.8307533539731683
=====

Classification Report untuk Random Forest:
=====
              precision    recall  f1-score   support

     0       0.67       0.67       0.67         6
     1       0.88       0.78       0.82         9
     2       0.90       1.00       0.95         9

   accuracy          0.83         24
  macro avg          0.81         24
 weighted avg          0.83         24

=====
Accuracy of Random Forest is: 83.33333333333334
=====

```

Gambar 4.13 Akurasi Random Forest

Hasil evaluasi kinerja model Random Forest (RF) menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 83.23% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 83.33% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 83.08%.

Dengan akurasi keseluruhan sekitar 83.33%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.3 K-Nearest Neighbor (KNN)

```
Hasil Precision, Recall, F1-score dari K-Nearest Neighbors:
=====
- Precision : 0.78125
- Recall   : 0.7083333333333334
- F1-score  : 0.7209558823529413
=====

Classification Report untuk K-Nearest Neighbors:
=====
              precision    recall  f1-score   support

     0           0.50       0.83       0.62         6
     1           0.75       0.67       0.71         9
     2           1.00       0.67       0.80         9

 accuracy          0.71         24
 macro avg         0.75       0.72       0.71         24
 weighted avg      0.78       0.71       0.72         24

=====
Accuracy of K-Nearest Neighbors is: 70.83333333333334
=====
```

Gambar 4.14 Akurasi KNN

Hasil evaluasi kinerja model KNN menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 78.12% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 70.83% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 72.10%.

Dengan akurasi keseluruhan sekitar 70.83%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.4 Bagging: Decision Tree

```
Hasil Precision, Recall, F1-score dari Bagging with Decision Tree:
=====
- Precision : 0.8322916666666668
- Recall    : 0.8333333333333334
- F1-score  : 0.8307533539731683
=====

Classification Report untuk Bagging with Decision Tree:
=====
              precision    recall  f1-score   support

     0           0.67       0.67       0.67         6
     1           0.88       0.78       0.82         9
     2           0.90       1.00       0.95         9

 accuracy          0.83         24
 macro avg         0.81       0.81       0.81         24
 weighted avg      0.83       0.83       0.83         24

=====
Accuracy of Bagging with Decision Tree is: 83.33333333333334
=====
```

Gambar 4.15 Akurasi Bagging: Decision Tree

Hasil evaluasi kinerja model Bagging: Decision Tree menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 83.23% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 83.33% dari keseluruhan data positif yang tersedia.

- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 83.08%.

Dengan akurasi keseluruhan sekitar 83.33%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.5 Bagging: Random forest

```

Hasil Precision, Recall, F1-score dari Bagging with Random Forest:
=====
- Precision : 0.870833333333332
- Recall    : 0.875
- F1-score  : 0.870414673046252
=====

Classification Report untuk Bagging with Random Forest:
=====
              precision    recall  f1-score   support

0             0.80         0.67         0.73         6
1             0.89         0.89         0.89         9
2             0.90         1.00         0.95         9

 accuracy          0.86         0.85         0.88         24
  macro avg         0.86         0.85         0.85         24
 weighted avg         0.87         0.88         0.87         24

=====
Accuracy of Bagging with Random Forest is: 87.5
=====

```

Gambar 4.16 Akurasi Bagging: Random Forest

Hasil evaluasi kinerja model Bagging: Random forest menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 87.08% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 87.5% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 87.04%.

Dengan akurasi keseluruhan sekitar 87.5%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.6 Naive-Bayes

```

Hasil Precision, Recall, F1-score dari Naive Bayes (Multinomial):
=====
- Precision : 0.6582792207792209
- Recall    : 0.625
- F1-score  : 0.6278846153846155
=====

Classification Report:
=====
              precision    recall  f1-score   support

0             0.43         0.50         0.46         6
1             0.64         0.78         0.70         9
2             0.83         0.56         0.67         9

 accuracy          0.63         0.61         0.62         24
  macro avg         0.63         0.61         0.61         24
 weighted avg         0.66         0.62         0.63         24

=====
Accuracy of Naive Bayes (Multinomial) is: 62.5
=====

```

Gambar 4.17 Naive Bayes

Hasil evaluasi kinerja model Naive-Bayes menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 65.82% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 62.5% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 62.79%.

Dengan akurasi keseluruhan sekitar 62.5%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.7 Artificial Neural Network: Backwards-Propagation

```

Precision, Recall, F1-score for ANN:
=====
- Precision: 0.7068452380952381
- Recall: 0.6666666666666666
- F1-score: 0.680595238095237
=====

Classification Report for ANN:
=====
              precision    recall  f1-score   support

     0       0.38         0.50         0.43         6
     1       0.86         0.67         0.75         9
     2       0.78         0.78         0.78         9

   accuracy          0.67         0.65         0.67        24
  macro avg          0.67         0.65         0.65        24
 weighted avg          0.71         0.67         0.68        24

=====
Accuracy of ANN: 66.66666666666666
=====

```

Gambar 4.18 Akurasi ANN

Hasil evaluasi kinerja model ANN: Backwards-Propagation menunjukkan bahwa:

- Precision: Model memiliki tingkat keakuratan sekitar 70.68% dalam mengklasifikasikan data positif.
- Recall: Model berhasil mengidentifikasi sekitar 66.67% dari keseluruhan data positif yang tersedia.
- F1-score: Merupakan rata-rata harmonis antara precision dan recall, yang dalam kasus ini sekitar 68.01%.

Dengan akurasi keseluruhan sekitar 66.67%, model ini menunjukkan kemampuan yang layak dalam melakukan prediksi pada data yang diberikan.

4.3.8 Perbandingan Evaluasi Model

	Accuracy DT	Accuracy RF	Accuracy KNN	Accuracy Bagging DT	Accuracy Bagging RF	Accuracy Naive Bayes	Accuracy ANN
0	70.833333	83.333333	70.833333	83.333333	87.5	62.5	66.666667

Gambar 4.19 Perbandingan evaluasi model

Setelah klasifikasi menggunakan beberapa model machine learning, didapatkan hasil sebagai berikut:

- Decision Tree (DT): 70.83%
- Random Forest (RF): 83.33%

- K-Nearest Neighbors (KNN): 70.83%
- Bagging Decision Tree (Bagging DT): 83.33%
- Bagging Random Forest (Bagging RF): 87.5%
- Naive Bayes: 62.5%
- Artificial Neural Network (ANN): 66.67%

Dapat disimpulkan bahwa model Bagging Random Forest memiliki akurasi tertinggi (87.5%), sedangkan model Naive Bayes memiliki akurasi terendah (62.5%). Model Random Forest dan Bagging Decision Tree juga menunjukkan performa yang baik dengan akurasi 83.33%.

BAB V

KESIMPULAN DAN SARAN

5.1 KESIMPULAN

Tujuan utama analisis ini adalah untuk menganalisis pola hidup mahasiswa Program Studi Teknologi Sains Data angkatan 2022 berdasarkan pendapatan per bulan menggunakan metode klasifikasi. Metode klasifikasi yang digunakan meliputi:

- Decision Tree: menghasilkan akurasi sebesar 71%
- Random Forest: menghasilkan akurasi sebesar 83%
- K-Nearest Neighbor (KNN): menghasilkan akurasi sebesar 71%
- Bagging dengan Decision Tree: menghasilkan akurasi sebesar 83%
- Bagging dengan Random Forest: menghasilkan akurasi sebesar 88%
- Naive Bayes: menghasilkan akurasi sebesar 63%
- Artificial Neural Network (ANN) dengan backward propagation: menghasilkan akurasi sebesar 67%

Dari tujuh metode klasifikasi yang telah diuji, metode Bagging dengan Random Forest menunjukkan kinerja terbaik dalam mengklasifikasikan pola hidup mahasiswa TSD 22 berdasarkan pendapatan per bulan, dengan akurasi tertinggi sebesar 88%. Hal ini menunjukkan bahwa metode ini sangat efektif dalam menangani kompleksitas dan variasi data pola hidup mahasiswa berdasarkan pendapatan per bulan.

Selain itu, variabel pengeluaran memegang peranan penting dalam menentukan pola hidup mahasiswa. Hal ini ditunjukkan oleh pentingnya variabel pengeluaran, yang memiliki kontribusi sekitar 34.6% dalam pengklasifikasian pola hidup mahasiswa berdasarkan pendapatan per bulan.

5.2 SARAN

Untuk meningkatkan kualitas penelitian di masa depan, ada beberapa saran yang bisa dipertimbangkan:

- Penelitian selanjutnya dapat melibatkan lebih banyak variabel yang mungkin termasuk dalam faktor-faktor yang mempengaruhi pendapatan mahasiswa seperti latar belakang keluarga, minat dan hobi, serta faktor-faktor lain selain variabel pendapatan dan pengeluaran.
- Penelitian berikutnya bisa menggunakan metode lain, tidak hanya klasifikasi tetapi juga clustering, untuk mendapatkan perspektif yang lebih luas tentang data.
- Penelitian selanjutnya bisa memperluas ranah yang dicakup, tidak hanya teknologi sains data angkatan 2022, tetapi seluruh mahasiswa fakultas teknologi maju dan multidisiplin (FTMM) atau bahkan seluruh mahasiswa Universitas Airlangga. Dengan begitu, data yang didapat bisa lebih banyak, lebih bervariasi, dan lebih representatif.

DAFTAR PUSTAKA

- Amri, F. (2015). Jaringan Syaraf Tiruan Untuk Memprediksi Peringkat Akreditasi Program Studi Perguruan Tinggi. *Jurnal Sains dan Informatika*, 1(1).
- Breiman, L. (1996). Bagging predictors. *Machine learning*, 24, 123-140.
- Breiman, L. (2001). Random forests. *Machine learning*, 45, 5-32.
- Creswell, J. W., & Creswell, J. D. (2017). *Research design: Qualitative, quantitative, and mixed methods approaches*. Sage publications.
- Dunham, M. H. (2006). *Data mining: Introductory and advanced topics*. Pearson Education India.
- Han, J., Pei, J., & Tong, H. (2022). *Data mining: concepts and techniques*. Morgan kaufmann.
- Satriani, P. (2018). *Pengaruh Penghasilan dan Gaya Hidup Terhadap Tingkat Konsumsi Mahasiswa IAIN Bengkulu (Studi pada Mahasiswa Fakultas Ekonomi dan Bisnis Islam)* (Doctoral dissertation, UIN Fatmawati Sukarno Bengkulu).
- Tobing, D. R. L. (2016). Analisis Hubungan Antara Pendapatan Dengan Perilaku Konsumsi (Studi Pada Mahasiswa Fakultas Ekonomi dan Bisnis Universitas Brawijaya). *Jurnal Ilmiah Mahasiswa FEB*, 3(2).
- Mafa'atih, M. M. (2020) IMPLEMENTASI ARTIFICIAL INTELLIGENCE UNTUK MEMPREDIKSI HARGA SEWA AIRBNB MENGGUNAKAN METODE RANDOM FOREST DAN PENERAPAN WEB APPLICATION MENGGUNAKAN FLASK. Sleman.
- Setiawan, S. I. A. (2011). Penerapan Jaringan Saraf Tiruan Metode Backpropagation Menggunakan VB 6. *Ultimatics: Jurnal Teknik Informatika*, 3(2), 23-28.
- Sugiyono, D. (2013). Metode penelitian pendidikan pendekatan kuantitatif, kualitatif dan R&D.
- Suntoro, J. (2019). *DATA MINING: Algoritma dan Implementasi dengan Pemrograman php*. Elex Media Komputindo.
- Hastuti, U. M. (2014). *ANALISIS KUALITAS PELAYANAN TEKNIK AREA KARANG TAHUN 2014 (Studi Pada PT Bermosacaro Selases Dijinal (BSD) Sebagai Rekan PT PLN (Persero) Area Karang)* (Doctoral dissertation, Fakultas Ilmu Sosial dan Ilmu Politik).
- Witten, I. H., Frank, E., Hall, M. A., Pal, C. J., & Data, M. (2005, June). Practical machine learning tools and techniques. In *Data mining* (Vol. 2, No. 4, pp. 403-413). Amsterdam, The Netherlands: Elsevier.

LAMPIRAN

Link Dataset:

<https://bit.ly/DatasetKelC>

Link Form:

<https://bit.ly/SurveiKelC>

Link Google Colab:

<https://bit.ly/ColabNotebookKelC>